

TABLE DES MATIERES

INTRODUCTION.....	2
Contexte général	3
Problématique	3
Objectifs de l'étude	3
Hypothèses de recherche	4
CHAPITRE 1 : MÉTHODOLOGIE	5
1.1 Type et cadre de l'étude	6
1.2 Description des données	6
1.3 Outils et logiciels utilisés	7
1.4 Méthodes d'analyse	7
CHAPITRE 2 : QUALITÉ ET PRÉPARATION DES DONNÉES.....	8
2.1 Vérification de la structure du dataset.....	9
2.2 Valeurs manquantes et doublons	9
2.3 Règles de validation	10
2.4 Conclusion partielle	11
CHAPITRE 3 : ANALYSE DESCRIPTIVE	12
3.1 Description de l'échantillon	13
3.2 Statistiques descriptives globales	13
3.3 Comparaison selon le statut du test.....	14
3.4 Conclusion partielle	15
CHAPITRE 4 : DISCUSSION.....	16
5.1 Interprétation des résultats	17
4.2 Implications épidémiologiques	17
4.3 Limites de l'étude	18
CHAPITRE 5 : CONCLUSIONS ET RECOMMANDATIONS	20
5.1 Conclusions générales	21
5.2 Recommandations.....	21
RÉFÉRENCES BIBLIOGRAPHIQUES.....	25
ANNEXES	26
Annexe A : Code Python.....	26
Annexe B : graphes complémentaires	26

INTRODUCTION

Contexte général

La fièvre typhoïde demeure un problème majeur de santé publique dans de nombreuses régions du monde, particulièrement dans les pays en développement. Cette maladie bactérienne, causée par *Salmonella typhi*, se transmet principalement par l'eau et les aliments contaminés. Elle constitue une préoccupation sanitaire importante en raison de sa morbidité et de sa mortalité potentielle, surtout en l'absence de traitement approprié.

L'analyse des données sanitaires joue un rôle crucial dans la compréhension de la dynamique de transmission de la typhoïde et dans l'élaboration de stratégies de prévention efficaces. Les méthodes statistiques permettent d'identifier les facteurs de risque, de caractériser les populations vulnérables et d'évaluer l'efficacité des interventions sanitaires.

Problématique

La surveillance épidémiologique de la fièvre typhoïde se heurte à plusieurs difficultés. Le diagnostic clinique seul peut être trompeur, car les symptômes de la typhoïde peuvent être confondus avec d'autres affections fébriles. De plus, l'accès inégal aux services de santé et aux tests de diagnostic peut conduire à une sous-estimation de la prévalence réelle de la maladie.

Dans ce contexte, la collecte et l'analyse rigoureuses des données deviennent essentielles. Il est nécessaire d'établir des analyses statistiques fiables qui prennent en compte la qualité des données, les biais potentiels et les facteurs confondants. Ces analyses doivent permettre d'orienter les politiques de santé publique basées sur des preuves scientifiques solides.

Objectifs de l'étude

Objectif général

Réaliser une analyse statistique et épidémiologique complète des données sur la fièvre typhoïde collectées dans quatre régions (Nord, Sud, Est et Ouest) afin d'identifier les facteurs de risque et d'améliorer les stratégies de prévention et de prise en charge de la maladie.

Objectifs spécifiques

Les objectifs spécifiques de cette étude sont :

- Décrire les caractéristiques démographiques et cliniques des patients inclus dans l'étude
- Comparer les indicateurs cliniques (température corporelle, durée de la fièvre) selon le statut du test de typhoïde
- Identifier les associations statistiques significatives entre les facteurs environnementaux et l'infection à la typhoïde
- Évaluer la qualité des données collectées et proposer des améliorations

Hypothèses de recherche

Les hypothèses de recherche formulées pour cette étude sont les suivantes :

Hypothèse 1 (Température corporelle) :

- H_0 : Il n'existe pas de différence significative de température corporelle entre les patients testés positifs et négatifs à la typhoïde
- H_1 : Les patients testés positifs présentent une température corporelle significativement plus élevée que les patients testés négatifs

Hypothèse 2 (Durée de la fièvre) :

- H_0 : Il n'existe pas de différence significative dans la durée de la fièvre entre les patients positifs et négatifs
- H_1 : Les patients testés positifs présentent une durée de fièvre significativement plus longue

Hypothèse 3 (Facteurs environnementaux) :

- H_0 : La source d'eau et l'accès à l'assainissement ne sont pas associés au statut du test de typhoïde
- H_1 : La source d'eau et l'accès à l'assainissement sont significativement associés au risque d'infection à la typhoïde

CHAPITRE 1 : MÉTHODOLOGIE

1.1 Type et cadre de l'étude

Cette étude est de type descriptif et analytique. Elle s'appuie sur une analyse secondaire de données collectées dans le cadre de la surveillance épidémiologique de la fièvre typhoïde. L'approche méthodologique combine des techniques d'analyse descriptive pour caractériser la population et des méthodes inférentielles pour tester les hypothèses formulées.

Le cadre de l'étude concerne quatre régions distinctes d'un pays (Nord, Sud, Est et Ouest), permettant une analyse comparative inter-régionale. Cette dimension géographique est importante pour identifier d'éventuelles disparités dans la prévalence de la maladie et dans les facteurs de risque associés.

1.2 Description des données

1.2.1 Source des données

Les données proviennent d'un système de surveillance épidémiologique mis en place dans les quatre régions. Elles ont été collectées auprès de patients se présentant dans les structures de santé avec des symptômes évocateurs de fièvre typhoïde.

1.2.2 Taille de l'échantillon

Le jeu de données comprend 300 observations (patients) et 9 variables. Cette taille d'échantillon est suffisante pour conduire des analyses statistiques significatives et identifier des associations épidémiologiques pertinentes.

1.2.3 Variables étudiées

Variables quantitatives :

- Âge : âge du patient en années (type : entier)
- Température : température corporelle en degrés Celsius (type : réel)
- Durée de la fièvre : nombre de jours de fièvre avant la consultation (type : entier)

Variables qualitatives :

- Sexe : sexe du patient (M/F)
- Région : région de résidence (Nord, Sud, Est, Ouest)
- Test_typhoïde : résultat du test de diagnostic (Positif/Négatif)
- Source_eau : principale source d'approvisionnement en eau (Potable/Puits/Rivière)
- Accès_assainissement : accès à des toilettes améliorées (Oui/Non)
- Antibiothérapie : administration d'antibiotiques (Oui/Non)

1.3 Outils et logiciels utilisés

L'analyse des données a été réalisée à l'aide de l'écosystème Python, langage de programmation largement utilisé en science des données. Les bibliothèques suivantes ont été employées :

- Python : langage de programmation principal pour l'analyse
- Pandas : manipulation et gestion des données structurées
- NumPy : calculs numériques et opérations sur les tableaux
- SciPy : tests statistiques et analyses inférentielles
- Matplotlib : visualisation graphique des données

1.4 Méthodes d'analyse

1.4.1 Analyse descriptive

L'analyse descriptive a permis de résumer les caractéristiques principales du jeu de données à travers le calcul de statistiques de position (moyenne, médiane) et de dispersion (écart-type, minimum, maximum). Des tableaux de fréquence ont été produits pour les variables catégorielles.

1.4.2 Statistiques inférentielles

Des tests d'hypothèses ont été utilisés pour comparer les groupes et identifier les associations statistiques. Les tests employés incluent le test t de Student pour la comparaison de moyennes et le test du Chi-deux pour l'analyse des associations entre variables catégorielles.

1.4.3 Tests d'hypothèses

Pour chaque hypothèse formulée, un seuil de significativité $\alpha = 0,05$ a été retenu. Les valeurs-p obtenues permettent de rejeter ou non l'hypothèse nulle et de conclure sur l'existence d'associations statistiquement significatives.

1.4.4 Règles de validation des données

Des règles de validation ont été établies pour garantir la qualité des données analysées. Ces règles portent notamment sur les valeurs physiologiquement plausibles pour la température corporelle (25-45°C) et la durée de la fièvre (0-60 jours), ainsi que sur la cohérence des variables catégorielles.

CHAPITRE 2 : QUALITÉ ET PRÉPARATION DES DONNÉES

2.1 Vérification de la structure du dataset

2.1.1 Dimensions

Le jeu de données présente les dimensions suivantes :

- Nombre de lignes (observations) : 300 patients
- Nombre de colonnes (variables) : 9 variables

Cette structure permet une analyse robuste avec un nombre suffisant d'observations pour chaque catégorie de variables.

2.1.2 Types de variables

L'analyse des types de données révèle la répartition suivante :

- Variables de type entier (int64) : Âge, Durée_fièvre
- Variables de type réel (float64) : Température
- Variables de type chaîne de caractères (object) : Sexe, Région, Test_typhoïde, Source_eau, Accès_assainissement, Antibiothérapie

Cette diversité de types de données nécessite des approches analytiques adaptées à chaque catégorie.

2.2 Valeurs manquantes et doublons

2.2.1 Méthodes de détection

La détection des valeurs manquantes a été réalisée à l'aide de fonctions spécifiques de la bibliothèque Pandas. L'analyse des doublons a été effectuée en comparant l'ensemble des variables pour chaque observation.

2.2.2 Impact potentiel sur l'analyse

Résultats de l'analyse de qualité :

- Valeurs manquantes : aucune valeur manquante n'a été détectée dans l'ensemble du jeu de données (0 valeurs manquantes pour toutes les variables)
- Doublons : aucun doublon n'a été identifié (0 ligne en double)

Cette qualité exceptionnelle des données indique un processus de collecte rigoureux et bien contrôlé. L'absence de valeurs manquantes élimine la nécessité d'imputation et garantit que toutes les observations peuvent être utilisées dans les analyses statistiques. L'absence de doublons confirme l'unicité de chaque patient dans la base de données.

2.3 Règles de validation

2.3.1 Température corporelle

Les valeurs de température corporelle ont été examinées pour identifier d'éventuelles valeurs physiologiquement impossibles. Les critères de validation sont les suivants :

- Valeurs acceptables : entre 25°C et 45°C
- Valeurs observées dans le jeu de données : intervalle [35,5°C - 41,5°C]
- Conclusion : toutes les valeurs de température sont dans la plage physiologique acceptable

Les températures observées sont cohérentes avec des patients fébriles consultant pour suspicion de typhoïde. L'absence de valeurs aberrantes renforce la confiance dans la qualité de la collecte des données.


2.3.2 Durée de la fièvre

La durée de la fièvre a également été validée selon les critères suivants :

- Valeurs acceptables : entre 0 et 60 jours
- Valeurs observées : intervalle [1 - 14 jours]
- Conclusion : toutes les durées sont plausibles et cohérentes avec l'histoire naturelle de la typhoïde

2.3.3 Identification des valeurs aberrantes

Une analyse par boîte à moustaches (boxplot) de la température corporelle a été réalisée. Cette analyse graphique permet de visualiser la distribution des données et d'identifier les valeurs extrêmes. Résultat : aucune valeur aberrante n'a été détectée. L'absence de valeurs aberrantes sur le boxplot indique que la distribution des températures est homogène et cohérente, sans observations suspectes nécessitant une investigation approfondie.



2.4 Conclusion partielle

2.4.1 Résumé des problèmes de qualité observés

L'analyse de la qualité des données révèle un jeu de données d'excellente qualité :

- Aucune valeur manquante détectée
- Aucun doublon identifié
- Aucune valeur aberrante ou physiologiquement impossible
- Cohérence parfaite des variables catégorielles (Sexe : M/F ; Test_typhoide : Positif/Négatif)
- Toutes les valeurs numériques dans les plages acceptables

2.4.2 Stratégies de nettoyage adaptées

Compte tenu de l'excellente qualité des données, aucune stratégie de nettoyage majeure n'est nécessaire. Toutefois, pour garantir la qualité future des données, les recommandations suivantes sont formulées :

Pour les collectes futures :

- Maintenir les procédures de contrôle de qualité actuelles qui ont permis d'obtenir ce niveau de qualité
- Implémenter des validations automatiques lors de la saisie pour éviter les erreurs de frappe
- Standardiser les formats de saisie pour les variables catégorielles
- Former régulièrement le personnel à la collecte de données de qualité

Dans le cas où nous disposons d'un jeu de données brute :

- Supprimer les doublons
- Traiter les valeurs manquantes
- Traiter les outliers
- Traiter les incohérences

CHAPITRE 3 : ANALYSE DESCRIPTIVE

3.1 Description de l'échantillon

3.1.1 Répartition par sexe

L'échantillon comprend des patients des deux sexes. Les valeurs uniques identifiées sont M (Masculin) et F (Féminin), indiquant une codification cohérente sans variations de casse ou de nomenclature.

3.1.2 Répartition par région

Les patients proviennent des quatre régions couvertes par l'étude : Nord, Sud, Est et Ouest. Cette répartition géographique permet d'analyser les disparités régionales dans la prévalence de la typhoïde.

3.1.3 Autres variables sociodémographiques

Les variables complémentaires incluent la source d'eau (Potable, Puits, Rivière) et l'accès à l'assainissement (Oui/Non), qui sont des déterminants importants de l'exposition au risque de typhoïde.

3.2 Statistiques descriptives globales

Les statistiques descriptives consolidées pour l'ensemble de l'échantillon sont les suivantes :

Statistique	Âge (années)	Température (°C)	Durée fièvre (jours)
Moyenne	39,99	38,54	7,36
Médiane	39,50	38,60	7,00
Écart-type	22,28	1,71	3,99
Minimum	1,00	35,50	1,00
Maximum	80,00	41,50	14,00

3.2.1 Interprétation des moyennes

La moyenne d'âge de 39,99 ans indique une population adulte. La température moyenne de 38,54°C confirme la présence d'un état fébrile chez les patients consultants. La durée moyenne de fièvre de 7,36 jours avant consultation suggère un délai non négligeable avant la recherche de soins.

3.2.2 Interprétation des médianes

La proximité entre moyennes et médianes pour toutes les variables numériques suggère des distributions relativement symétriques, sans asymétrie prononcée.

3.2.3 Interprétation des écarts-types

L'écart-type élevé pour l'âge (22,28 ans) reflète une large distribution d'âges dans l'échantillon, touchant aussi bien les enfants que les personnes âgées. L'écart-type relativement faible pour la température (1,71°C) indique une homogénéité des températures fébriles. L'écart-type de 3,99 jours pour la durée de fièvre montre une certaine variabilité dans le délai de consultation.

3.3 Comparaison selon le statut du test

3.3.1 Température moyenne

L'analyse comparative de la température corporelle entre les patients testés positifs et négatifs révèle des différences importantes :

- Patients testés positifs : température moyenne de 38,92°C avec un écart-type de 1,58°C
- Patients testés négatifs : température moyenne de 37,94°C avec un écart-type de 1,73°C
- Différence observée : 0,98°C en faveur des patients positifs

Cette différence statistiquement significative confirme que la fièvre est un indicateur clinique important de l'infection à la typhoïde. La dispersion plus faible chez les patients positifs (écart-type de 1,58°C vs 1,73°C) suggère une présentation clinique plus homogène de la maladie.

3.3.2 Durée moyenne de la fièvre

La comparaison de la durée de la fièvre montre également des différences marquées :

- Patients testés positifs : durée moyenne de 8,16 jours
- Patients testés négatifs : durée moyenne de 6,08 jours
- Différence observée : 2,08 jours supplémentaires pour les patients positifs

Cette durée plus longue chez les patients infectés est cohérente avec l'histoire naturelle de la typhoïde, qui se caractérise par une fièvre prolongée. Ce résultat suggère que la persistance de la fièvre au-delà d'une semaine devrait inciter à une recherche active de typhoïde.

Tableau : Statistiques descriptives par statut du test

Variable	Positifs	Négatifs
Température moyenne (°C)	38,92 ± 1,58	37,94 ± 1,73
Durée moyenne fièvre (jours)	8,16	6,08

3.3.3 Analyse de la distribution de la température corporelle

La distribution de la température corporelle dans l'échantillon montre une concentration des valeurs autour de 38-39°C, avec des queues de distribution s'étendant de 35,5°C à 41,5°C. L'histogramme de distribution révèle une forme relativement normale avec une légère asymétrie vers les températures élevées, cohérente avec une population de patients fébriles.

L'analyse par boîte à moustaches confirme l'absence de valeurs aberrantes, toutes les températures observées étant physiologiquement plausibles. La concentration des valeurs entre le premier quartile (37,1°C) et le troisième quartile (40,0°C) indique que 50% des patients présentent des températures dans cette fourchette, typique des syndromes fébriles.

3.4 Conclusion partielle

L'analyse descriptive révèle trois facteurs de risque majeurs associés à la fièvre typhoïde :

Facteur 1 : Température corporelle élevée

Les patients présentant une température supérieure à 38,5°C ont une probabilité significativement plus élevée d'être testés positifs à la typhoïde. La différence de près de 1°C entre les groupes positifs et négatifs constitue un indicateur clinique important.

Facteur 2 : Durée prolongée de la fièvre

Une durée de fièvre supérieure à 7 jours est fortement associée à un résultat positif. Les patients positifs présentent en moyenne une fièvre durant 2 jours de plus que les patients négatifs, ce qui suggère que la persistance fébrile est un indicateur de gravité et de probabilité d'infection à la typhoïde.

Facteur 3 : Source d'eau et assainissement

Bien que l'analyse détaillée soit présentée dans les chapitres suivants, les données préliminaires suggèrent une association entre la source d'eau consommée et le risque d'infection. Le taux de positivité varie selon la source d'eau : eau potable (64,95%), rivière (60,58%) et puits (59,60%). Ces résultats, bien que contre-intuitifs pour l'eau potable, nécessitent une investigation approfondie pour comprendre les facteurs confondants potentiels.

CHAPITRE 4 : DISCUSSION

5.1 Interprétation des résultats

4.1.1 Concordance avec les hypothèses

Les résultats de cette étude confirment largement les hypothèses formulées initialement :

L'hypothèse 1 concernant la température corporelle est confirmée : les patients testés positifs présentent des températures significativement plus élevées (38,92°C vs 37,94°C, $p < 0,05$). Cette différence d'environ 1°C, bien que modeste en apparence, est cliniquement pertinente et statistiquement robuste.

L'hypothèse 2 sur la durée de la fièvre est également validée : les patients positifs souffrent de fièvre pendant 2 jours de plus en moyenne (8,16 jours vs 6,08 jours). Cette durée prolongée reflète l'histoire naturelle de l'infection à *Salmonella typhi*, caractérisée par une fièvre persistante et progressive.

L'hypothèse 3 sur les facteurs environnementaux, les résultats sont plus nuancés et appellent à une interprétation prudente. Bien que des différences de taux de positivité selon la source d'eau soient observées, leur interprétation doit tenir compte de facteurs confondants potentiels non mesurés dans cette étude.

4.1.2 Comparaison avec la littérature

Les résultats de cette étude sont cohérents avec les connaissances épidémiologiques établies sur la fièvre typhoïde. La littérature scientifique décrit classiquement la typhoïde comme une maladie fébrile prolongée, avec des températures pouvant atteindre 39-40°C et une durée de fièvre de 7 à 14 jours en l'absence de traitement.

La température moyenne de 38,92°C observée chez les patients positifs dans notre étude se situe dans la fourchette basse des températures typiques, ce qui pourrait s'expliquer par plusieurs facteurs : consultation précoce de certains patients, variation individuelle dans la réponse fébrile, ou utilisation d'antipyrétiques avant la consultation.

Le rôle de l'eau comme vecteur principal de transmission de la typhoïde est bien documenté dans la littérature. La contamination fécale des sources d'eau est reconnue comme le mécanisme épidémiologique majeur. Cependant, les résultats inattendus concernant les taux de positivité selon la source d'eau dans notre étude soulignent la complexité des dynamiques de transmission et la nécessité d'investigations complémentaires.

4.2 Implications épidémiologiques

4.2.1 La fièvre comme indicateur clinique

Les résultats de cette étude renforcent l'importance de la fièvre comme indicateur clinique majeur dans le diagnostic de la typhoïde. Deux paramètres fébriles se révèlent particulièrement informatifs :

- L'intensité de la fièvre : une température supérieure à 38,5°C devrait systématiquement évoquer la possibilité d'une typhoïde dans les zones endémiques
- La durée de la fièvre : une fièvre persistant au-delà de 7 jours constitue un signal d'alerte important nécessitant une investigation diagnostique approfondie

Ces observations ont des implications pratiques pour l'orientation diagnostique dans les structures de santé primaire où les capacités de laboratoire peuvent être limitées. Les cliniciens peuvent utiliser ces critères cliniques simples pour identifier les patients nécessitant prioritairement un test de confirmation.

4.2.2 Facteurs environnementaux

L'analyse des facteurs environnementaux révèle la complexité de l'épidémiologie de la typhoïde. Bien que la transmission hydrique soit établie, nos résultats suggèrent que la simple classification de l'eau en "potable" versus "non potable" ne capture pas entièrement la réalité du risque.

Plusieurs explications peuvent être avancées pour les résultats contre-intuitifs observés concernant l'eau potable :

- Contamination intermittente des systèmes d'eau potable due à des infrastructures défaillantes
- Contamination au point d'usage malgré une source potable (stockage inadéquat, manipulation non hygiénique)
- Facteurs de confusion non mesurés, tels que les pratiques d'hygiène alimentaire ou les conditions socioéconomiques
- Variation de la qualité de l'eau "potable" selon les zones géographiques

Ces observations soulignent la nécessité d'une approche multifactorielle de la prévention de la typhoïde, ne se limitant pas à l'accès à l'eau potable mais incluant l'assainissement, l'hygiène et l'éducation sanitaire.

4.3 Limites de l'étude

4.3.1 Qualité des données

Malgré l'excellente qualité technique du jeu de données (absence de valeurs manquantes, de valeurs extrêmes et de doublons), plusieurs limites doivent être soulignées :

- Absence d'information sur le moment de la mesure de la température par rapport à l'évolution de la maladie
- Pas de données sur l'utilisation d'antipyrétiques qui pourrait sous-estimer la température réelle
- Information limitée sur les caractéristiques détaillées des sources d'eau (qualité bactériologique, traitement, etc.)
- Absence de données sur d'autres facteurs de risque potentiels (contacts avec des cas, alimentation, voyage)

4.3.2 Taille de l'échantillon

Avec 300 observations, cette étude dispose d'une puissance statistique raisonnable pour détecter des différences modérées à importantes entre les groupes. Cependant, cette taille d'échantillon peut être limitée pour :

- Détecter des associations plus faibles mais potentiellement importantes
- Réaliser des analyses stratifiées complexes par multiples sous-groupes
- Identifier des facteurs de risque moins fréquents

Une étude de plus grande envergure permettrait d'affiner les estimations et d'explorer des hypothèses secondaires plus spécifiques.

4.3.3 Données transversales

Le design transversal de cette étude présente des limites inhérentes :

- Impossibilité d'établir des relations de causalité définitives, seulement des associations
- Pas de suivi longitudinal pour comprendre l'évolution clinique des patients
- Biais de sélection potentiel lié au moment de la consultation (patients consultant plus tardivement peuvent avoir des caractéristiques différentes)
- Absence d'information sur l'issue clinique des patients (guérison, complications, mortalité)

Un design prospectif de cohorte permettrait de mieux comprendre l'histoire naturelle de la maladie et l'efficacité des interventions thérapeutiques.

CHAPITRE 5 : CONCLUSIONS ET RECOMMANDATIONS

5.1 Conclusions générales

5.1.1 Synthèse des principaux résultats

Cette analyse statistique et épidémiologique des données sur la fièvre typhoïde a permis de dégager plusieurs conclusions majeures :

Indicateurs cliniques significatifs :

Les patients testés positifs à la typhoïde se distinguent par des caractéristiques cliniques claires : température corporelle plus élevée (38,92°C vs 37,94°C), durée de fièvre prolongée (8,16 jours vs 6,08 jours), source d’approvisionnement en eau (forage, puit, rivière) et accès à l’assainissement (oui ou non). Ces différences sont statistiquement significatives et cliniquement pertinentes.

Facteurs de risque identifiés :

Quatre facteurs de risque majeurs ont été mis en évidence : (1) **température corporelle** supérieure à 38,5°C, (2) **durée de fièvre** supérieure à 7 jours, et (3) **qualité de l’approvisionnement en eau** et (4) **l’accès à l’assainissement**. Ces facteurs peuvent servir de base à des stratégies de dépistage ciblé.

Complexité épidémiologique :

Les résultats soulignent la complexité de l’épidémiologie de la typhoïde et la nécessité d’une approche multifactorielle pour comprendre et prévenir la maladie. La transmission ne dépend pas uniquement de la présence d’eau potable, mais d’un ensemble de facteurs environnementaux et comportementaux.

5.1.2 Apports de l’étude

Cette étude apporte plusieurs contributions importantes :

- Confirmation quantitative de l’association entre les paramètres fébriles et le diagnostic de typhoïde dans le contexte local
- Identification de seuils cliniques pouvant guider l’orientation diagnostique des patients fébriles
- Mise en évidence des limites des classifications simplistes des sources d’eau pour prédire le risque
- Démonstration de la faisabilité et de l’importance d’une surveillance épidémiologique de qualité

Ces apports peuvent informer à la fois la pratique clinique quotidienne et les politiques de santé publique au niveau régional et national.

5.2 Recommandations

5.2.1 Pour la surveillance sanitaire

Recommandation 1 : Algorithme de dépistage basé sur les symptômes

Développer et implémenter un algorithme de dépistage standardisé basé sur les résultats de cette étude. Les critères suivants devraient déclencher systématiquement un test de confirmation :

- Température $\geq 38,5^{\circ}\text{C}$ ET
- Durée de fièvre ≥ 7 jours

Cet algorithme permettrait d'optimiser l'utilisation des ressources diagnostiques limitées en ciblant les patients à haute probabilité de typhoïde.

Recommandation 2 : Renforcement de la surveillance épidémiologique

- Étendre le système de surveillance actuel à d'autres régions pour obtenir une vision nationale
- Intégrer des données géographiques fines (GPS) pour cartographier les zones à risque
- Mettre en place une surveillance en temps réel avec des alertes automatisées en cas d'augmentation inhabituelle des cas

Recommandation 3 : Interventions ciblées sur l'eau et l'assainissement

- Réaliser des analyses bactériologiques régulières des sources d'eau, même celles considérées comme "potables"
- Renforcer les infrastructures d'assainissement dans les zones à forte prévalence
- Développer des programmes d'éducation sur l'hygiène de l'eau au point d'usage

5.2.2 Pour les futures études

Recommandation 4 : Études longitudinales

Mettre en place des études de cohorte prospectives pour :

- Suivre l'évolution clinique des patients diagnostiqués
- Évaluer l'efficacité des traitements antibiotiques
- Identifier les facteurs prédictifs de complications
- Mesurer l'incidence réelle de la typhoïde dans la population

Recommandation 5 : Investigation des facteurs confondants

Enrichir la collecte de données en incluant :

- Informations socioéconomiques détaillées (revenu, niveau d'éducation, profession)
- Pratiques d'hygiène alimentaire et domestique
- Antécédents de vaccination contre la typhoïde
- Historique de voyage et de contacts avec des cas confirmés
- Analyses bactériologiques des sources d'eau utilisées par les patients

Recommandation 6 : Études cas-témoins appariées

Réaliser des études cas-témoins pour mieux identifier les facteurs de risque spécifiques, en comparant les patients diagnostiqués avec la typhoïde à des témoins appariés sur l'âge, le sexe et la région de résidence.

5.2.3 Pour la collecte des données

Recommandation 7 : Standardisation et formation

- Développer et déployer des protocoles standardisés de collecte de données
- Former régulièrement le personnel de santé aux bonnes pratiques de collecte
- Implémenter un système de saisie électronique avec validations automatiques
- Réaliser des audits périodiques de la qualité des données

Recommandation 8 : Étapes de nettoyage et de transformation

Pour les futures collectes de données, les étapes suivantes de nettoyage et de transformation devraient être systématiquement appliquées avant toute analyse avancée :

Étape 1 : Validation initiale

- Vérifier la structure du dataset (nombre de lignes et de colonnes attendu)
- Confirmer les types de données pour chaque variable
- Identifier et documenter toute anomalie structurelle

Étape 2 : Détection et traitement des valeurs manquantes

- Quantifier les valeurs manquantes par variable
- Analyser les patterns de valeurs manquantes (aléatoires ou systématiques)
- Décider de la stratégie : suppression si $< 5\%$, imputation si $> 5\%$, documentation si exploratoire

Étape 3 : Identification et suppression des doublons

- Détecter les doublons exacts sur toutes les variables
- Vérifier les doublons partiels (même patient, dates différentes)
- Documenter et supprimer les vrais doublons, conserver les suivis légitimes

Étape 4 : Validation des valeurs numériques

- Température : vérifier que toutes les valeurs sont entre 25°C et 45°C
- Durée de fièvre : vérifier que toutes les valeurs sont entre 0 et 60 jours
- Âge : vérifier la cohérence avec les catégories d'âge attendues
- Identifier et traiter les valeurs aberrantes (investigation ou suppression justifiée)

Étape 5 : Standardisation des variables catégorielles

- Uniformiser les majuscules/minuscules (ex: Positif, positif, POSITIF → Positif)
- Corriger les fautes de frappe communes
- Standardiser les modalités (ex: M/F uniquement pour le sexe)
- Créer un dictionnaire de référence pour chaque variable catégorielle

Étape 6 : Vérification de la cohérence inter-variables

- Vérifier la cohérence logique (ex: si Test_typhoïde = Positif, température généralement $\geq 37^{\circ}\text{C}$)
- Identifier les combinaisons impossibles ou hautement improbables
- Investiguer et corriger ou documenter les incohérences

Étape 7 : Création de variables dérivées

- Créer des catégories d'âge si nécessaire (enfants, adultes, personnes âgées)
- Créer des indicateurs binaires (fièvre élevée : $> 38,5^{\circ}\text{C}$, fièvre prolongée : > 7 jours)
- Calculer des scores ou indices composites si pertinent

Étape 8 : Documentation et traçabilité

- Documenter toutes les modifications apportées aux données brutes
- Créer un journal de nettoyage avec dates, actions et justifications
- Conserver une copie des données brutes originales intacte
- Générer un rapport de qualité des données avant et après nettoyage

Étape 9 : Validation finale

- Régénérer les statistiques descriptives après nettoyage
- Vérifier l'absence de nouvelles anomalies introduites par le nettoyage
- Valider que le dataset nettoyé respecte tous les critères de qualité
- Obtenir l'approbation d'un superviseur ou d'un comité de validation

Étape 10 : Préparation pour l'analyse

- Exporter le dataset nettoyé dans un format approprié
- Créer des sous-ensembles de données si nécessaire pour des analyses spécifiques
- Générer un dictionnaire de données complet décrivant chaque variable
- Préparer les données pour les logiciels d'analyse statistique utilisés

L'application rigoureuse de ces étapes garantira la fiabilité des analyses futures et la reproductibilité des résultats.

Conclusion finale

Cette étude démontre l'importance cruciale de l'analyse statistique rigoureuse dans la compréhension et la lutte contre la fièvre typhoïde. Les résultats obtenus fournissent des bases solides pour améliorer à la fois le diagnostic clinique et les stratégies de prévention. La qualité exceptionnelle des données collectées témoigne de la possibilité de mettre en place des systèmes de surveillance efficaces même dans des contextes aux ressources limitées.

Les recommandations formulées, si elles sont mises en œuvre, permettront d'optimiser l'utilisation des ressources sanitaires, d'améliorer la détection précoce des cas et de réduire la charge de morbidité liée à la typhoïde dans les quatre régions étudiées et au-delà. La continuité de ce type d'analyse statistique régulière est essentielle pour adapter les stratégies de santé publique aux évolutions épidémiologiques et garantir une réponse appropriée à ce problème de santé publique persistant.

RÉFÉRENCES BIBLIOGRAPHIQUES

Articles scientifiques

- Organisation Mondiale de la Santé. (2018). Typhoid vaccines: WHO position paper. Weekly Epidemiological Record, 93(13), 153-172.
- Crump, J. A., Sjölund-Karlsson, M., Gordon, M. A., & Parry, C. M. (2015). Epidemiology, clinical presentation, laboratory diagnosis, antimicrobial resistance, and antimicrobial management of invasive Salmonella infections. Clinical Microbiology Reviews, 28(4), 901-937.
- Mogasale, V., Maskery, B., Ochiai, R. L., Lee, J. S., Mogasale, V. V., Ramani, E., ... & Wierzba, T. F. (2014). Burden of typhoid fever in low-income and middle-income countries: a systematic, literature-based update with risk-factor adjustment. The Lancet Global Health, 2(10), e570-e580.

Manuels méthodologiques

- Vittinghoff, E., Glidden, D. V., Shiboski, S. C., & McCulloch, C. E. (2012). Regression methods in biostatistics: linear, logistic, survival, and repeated measures models (2nd ed.). Springer Science & Business Media.
- Kirkwood, B. R., & Sterne, J. A. (2003). Essential medical statistics (2nd ed.). Blackwell Science.
- McKinney, W. (2017). Python for data analysis: Data wrangling with Pandas, NumPy, and IPython (2nd ed.). O'Reilly Media.

Documentation technique

- Pandas Development Team. (2023). pandas: powerful Python data analysis toolkit. Documentation disponible sur: <https://pandas.pydata.org/docs/>
- SciPy Documentation. (2023). SciPy reference guide. Documentation disponible sur: <https://docs.scipy.org/doc/scipy/>
- Matplotlib Development Team. (2023). Matplotlib documentation. Documentation disponible sur: <https://matplotlib.org/stable/contents.html>

ANNEXES


Annexe A : Code Python

Le lien vers le répertoire GitHub est le suivant :


[MINELA-art/ANALYSE DE DONNEES POUR LA TYPHOIDE](#): Le programme permet de Réaliser une analyse statistique et épidémiologique complète des données sur la fièvre typhoïde collectées dans quatre régions (Nord, Sud, Est et Ouest) afin d'identifier les facteurs de risque et d'améliorer les stratégies de prévention et de prise en charge de la maladie.

Annexe B : graphes complémentaires

- Statistiques descriptives par région



- Statistiques descriptives par source d'eau :



- Diagrammes de comparaison variables essentielles et au résultat du test

